

Лекция 16

Использование самоорганизации в сети Веб для повышения эффективности ИПС.

Как показал опыт многие понятия и методы, которые разрабатывались в рамках традиционных ИПС, показали ограниченную применимость, а иногда и полную непригодность в сети гипертекстовых документов WWW.

В первые годы становления этой сети, когда устойчиво наметился экспоненциальный рост объемов накопленных ресурсов в этой сети, создавались поисковые системы, заимствовавшие подходы и алгоритмы из традиционных ИПС, которые работали с ограниченными и статическими коллекциями документов. Но уже к концу 90-х годов стало очевидно, что возможности таких систем не позволяют справляться с динамикой Веб. Параллельно проводились исследования феномена этой сети, ее структуры, закономерностей и поведения пользователей в этой сети. Постепенно приходило понимание природы и специфических особенностей данной сети. В частности, было показано, что в данной сети происходят процессы самоорганизации. Это осознание привело к появлению целого класса подходов к организации поиска информации в сети, существенным образом учитывающих выявленные особенности, что позволило расширить спектр возможностей поисковых систем и заметно повысить их эффективность.

Прежде всего, необходимо указать на тот факт, что самое главное отличие гипертекстовых документов, содержащихся в данной сети, от текстовых коллекций традиционных ИПС заключается в наличии в них гиперссылок. Этот факт приводит к появлению совершенно новых задач, которых принципиально не могло быть в традиционных системах. Гиперссылочный граф сети Веб органично эволюционирует без какой-либо централизованной координации, демонстрируя при этом как глобальные так и локальные свойства.

Естественной моделью представления структуры Веб является ориентированный граф $G(V, E)$, в котором вершины $v \in V$ соответствуют веб-страницам, а дуги (направленные ребра) $e(u, v)$, $u, v \in V$, $e \in E$ - соединяющим страницы гиперссылкам. Расстояние $d(u, v)$ между узлами u и v в графе без учета весов ребер равно наименьшему числу гиперссылок, по которым можно пройти из u в v . В рамках этой модели задача анализа структуры связей между страницами - это задача анализа структуры графа.

Степенной закон распределения гиперссылок в веб-графе.

Как показали исследования, к веб-графу не применимы модели, которые были детально изучены в рамках теории случайных графов. В нем четко просматриваются определенные регулярности. Например, в первом

приближении вероятность появления новой ссылки у веб-страницы подчиняется *степенному закону*:

$$\Pr(исх = k) \propto \frac{1}{k^{a_{исх}}} \qquad \Pr(вх = k) \propto \frac{1}{k^{a_{вх}}}$$

где k - количество исходящих или входящих гиперссылок, $a_{исх} = 2.45$, $a_{вх} = 2.1$.

Вновь возникающий узел веб-графа устанавливает соединения с уже существующими узлами не равновероятно, но с большей вероятностью с узлами, уже имеющими большое количество связей с другими узлами, т.е. действует принцип “Победителям достается все”.

Структура “бабочка”.

Проведенное в 1999 г. исследование [1] на примере более 200 млн. веб-страниц обнаружило широкомасштабную структуру в веб-графе, которая содержала центральное сильно связанное ядро (SCC), подграф IN, содержащий узлы, направленные в SCC, подграф OUT, состоящий из узлов с входящими ссылками из OUT, и, наконец, относительно изолированные отростки, прикрепленные к какой-либо одной из трех больших компонент.




Рисунок 1. Модель веб-графа “бабочка”.

Также было установлено, что подграфы, выделенные по определенному критерию (принадлежность домену, частота ключевых слов и др.) также демонстрировали аналогичную структуру, хотя относительные размеры составных компонент варьировались.

Поиск ресурсов в сети Веб.

В период становления сети Веб сбор документов выполнялся “пауками” малого и среднего масштаба.

С 1996 г. по 1999 г. происходило уменьшение степени охвата поисковыми системами:

■ 1997 г. - 35%

■ 1999 г. - 18%.

После 1999 г. рост Веб замедлился, функциональность сети улучшилась, как результат – степень охвата увеличилась до 45% - 55% (2000 г.-Google).

При выдаче ответа на запрос релевантными оказывается лишь небольшая доля из всех выданных и следовательно еще меньшая доля из скачанных пауком из Веб.

Естественный вопрос: возможно ли организовать приоритетный сбор ресурсов из Веб?

При этом следует руководствоваться следующими целями:

- Предпочтение должно отдаваться наиболее релевантным ресурсам.
- Часто изменяемые документы могут быть предпочтительными для некоторых приложений, например новостных порталов.
- Для вертикальных порталов, обслуживающие запросы, относящиеся к одной или нескольким обширным темам, требуется строить индексы из документов, относящихся только к этим темам.

Сфокусированный обход веб-графа.

Предположим, что случайным образом выбираются две веб-страницы, и для них вычисляется подобие на основе косинусной метрики. Можно ожидать, что получится очень маленькая величина, причем в основном за счет слов, не отражающих специфику данных документов (шум). Если же вторая страница выбирается случайно из ближайшего окружения первой страницы, то результат будет другой. Рассмотрим следующие варианты выбора двух документов:

- Случайным образом выбираются два документа, вычисляется косинусная метрика подобия TF-IDF (случайная пара).
- Случайным образом выбираются два документа, связанных гиперссылкой с общим для них документом, выбранным случайным образом из коллекции; также оценивается их подобие (потомок).
- Для случайной страницы *и* выбираются документы, связанные с ней гиперссылками, но имеющие общий хост (потомок из одного домена).

- Для случайной страницы u выбираются документы, связанные с ней гиперссылками, но принадлежащие различным хостам (потомок из другого домена).

В результате эксперимента [2], проведенного на 100 тыс. страниц из хранилища поисковой системы были получены результаты, представленные на рис.2.




Рисунок 2. Оценка степени подобия для случайной пары веб-страниц.

Данные результаты подтверждают то, что сеть Веб тематически кластеризована.

В связи с этим возникает важный вопрос: возможно ли заменить ли пассивное расширение области просмотра сетевым роботом в веб-графе на активное расширение?

То есть, если стандартный сетевой робот, использующий стратегию “приоритет в ширину” будет последовательно уровень за уровнем скачивать страницы независимо от их релевантности, то сфокусированный робот должен игнорировать нерелевантные документы (рис. 3).




Рисунок 3. Стандартный робот *vis* сфокусированный робот.

Если все рассматриваемые страницы с точки зрения соответствия интересующей тематики разделить на “положительные” и “отрицательные”, то можно сформулировать следующую гипотезу:

Радиус-1 гипотеза: если страница u “положительная”, и с ней связана гиперссылкой страница v , тогда вероятность того, что v “положительная”, выше, чем соответствующая вероятность у случайно выбранной из веб-страницы.

На основе этой гипотезы можно предложить блок-схему работы сфокусированного сетевого робота, представленную на рис. 4.




Рисунок 4. Блок-схема работы сфокусированного сетевого робота.

Когда робот скачивает новую страницу u , она затем предьявляется классификатору на проверку. Если классификатор признает ее “положительной”, то исходящие ссылки со страницы u добавляются в очередь, иначе исходящие игнорируются. В качестве классификатора могут быть использованы слова из запроса пользователя или слова из стартового подмножества документов.

К сожалению, при расширении *Радиус-1* плохо выявляются концентраторы, поскольку имеется очень мало исходящих ссылок для анализа.

Серьезная проблема состоит в том, что для сфокусированного робота очень часто сложно учитывать то, что тематически нерелевантные документы часто могут приводить к высокорелевантным документам. Например, очень много публикаций по нейронным сетям находится на домашних страницах исследователей, работающих в подразделениях университетов. И хотя университетская страница с точки зрения сфокусированного робота имеет очень низкую оценку по релевантности, оптимальной стратегией было бы перемещение от университетской страницы к страницам подразделений и далее к домашним страницам исследователей.

В связи с этим требуется выполнить дополнительное расширение.

Радиус-2 гипотеза: если страница u указывает на многие страницы v с большими значениями $R(v)$, то u является хорошим концентратором. Ближняя к ней страница w , связанная с u гиперссылкой (исходящей с u)

предположительно будет иметь более высокую релевантность, чем случайно выбранная страница из Веб.

В результате двух последовательных расширений строится *контекстный граф*, содержащий узлы из двух уровней (рис. 5).




Рисунок 5. Контекстный граф.

На рис. 6 представлена операционная схема работы сфокусированного сетевого робота.




Рисунок 6. Операционная схема работы сфокусированного сетевого робота

Модифицированная структура робота (контекстно-сфокусированного робота) (рис. 7) включает в себя несколько классификаторов и оптимизирована для поиска документов и отнесения их к различным категориям на основе ожидаемого расстояния от целевого документа.

Классификаторы пытаются предсказывать на каком расстоянии от целевого документа находится анализируемый в данный момент документ.

Алгоритм работы такого робота включает в себя два основных этапа:

1. Фаза инициализации, при которой строится контекстный граф и строятся соответствующие классификаторы для каждого из стартовых документов.
2. Фаза обхода веб-графа, при которой используются классификаторы для управления поиском и текущего обновления контекстного графа.

Обучение классификаторов происходит с помощью байесовских классификаторов на основе метрики TF-IDF.

В результате классификации каждый из поступающих от робота документов помещается в соответствующую очередь. Самой приоритетной является очередь 1.




Рисунок 7. Структура контекстно-сфокусированного робота-“паука”.

На рисунке 8 приведены результаты сравнительного эксперимента [4] для трех типов сетевых роботов-“пауков”. В качестве стартовых было взято 10 документов и построено 10 контекстных графов глубиной 4 гиперссылки. Число документов на каждом уровне ограничивалось (до 300). Было использовано 5 Байесовских классификаторов и соответственно столько же очередей.




Рисунок 8. Результаты сравнительного эксперимента.

Веб-сообщества (тематические сообщества)

Предпосылкой для моделей и алгоритмов идентификации веб-сообществ по праву можно считать цитирование – учет количества входящих ссылок на веб-ресурс. Это был первый опыт учета гипертекстовых связей при поиске.

Прототипом алгоритмов идентификации веб-сообществ можно считать алгоритм HITS. Чуть позже, в 1998 году, заложенные в цитировании и PageRank принципы послужили основой для появления понятия веб-сообщество (web community) [5,6,13].

Стоит заметить, что первоначально условия для понятия “веб-сообщество” были менее жесткие [13], т.к. плотность веб-графа была меньше. Позднее, когда количество связей в веб-графе многократно увеличилось (до 92% вершин сейчас связано), в [5,6] было предложено определение, которое подразумевало, что количество исходящих ссылок на членов веб-сообщества из веб-ресурса, принадлежащего сообществу, должно быть больше, чем наружу. Такие сообщества удобно извлекать как подграфы из веб-графа используя алгоритм поиска максимального потока.

На сегодняшний день наиболее проработана тема в работах [7, 8, 9]. Описанные в них исследования проводились на достаточно больших объемах данных (более 23 млн. веб-ресурсов) с использованием суперкомпьютерных вычислений.

Практическая польза веб-сообществ в поисковых системах может быть сведена к улучшению алгоритмов ранжирования и достижению большей релевантности. Кроме того, в определенных случаях, возможно повышение точности и полноты за счет направленного индексирования в рамках определенного сообщества и его тематики.

Идентификация веб-сообществ на основе ПМС

Как уже указывалось выше, естественной моделью представления структуры Интернет является ориентированный граф, в котором вершины соответствуют страницам, а ребра - соединяющим страницы гиперссылкам (рис. 9). В рамках этой модели задача анализа структуры связей между страницами - это задача анализа структуры графа. В конечном счете, задача сводится к задаче о максимальном потоке в сетях или максимальном потоке минимальной стоимости (ПМС) [10].




Рисунок 9. Веб-граф и веб-сообщество

Поиск максимального потока является ядром предложенного в [12, 6] алгоритма идентификации веб-сообществ (см. табл. 1).

Таким образом, структуру сети Интернет представляют как граф. Граф мы можем рассматривать как сеть, в масштабах которой решается задача о ПМС. Будем называть сеть с вершиной s , выбранной в качестве истока, и с вершиной t , выбранной в качестве стока, *транспортной st -сетью* (рис. 10)




Рисунок 10. Транспортная st -сеть.

Транспортная сеть - есть st -сеть с положительными весами ребер, которые будем называть пропускными способностями. Поток в транспортной сети есть множество ребер с неотрицательными весами, в дальнейшем реберными

потоками, которые удовлетворяют требованию того, что ни один поток в ребре не может быть больше пропускной способности ребра и что суммарный поток, поступающий в каждую внутреннюю вершину, равен суммарному потоку, вытекающему из этой вершины.

Пусть задана *st*-сеть. Требуется найти такой поток, что никакой другой поток из *s* в *t* не обладает большей мощностью. Будем называть такой поток максимальным потоком, а задачу построения такого потока в сети будем называть *задачей о максимальном потоке*.

Подход к решению задачи о максимальном потоке был разработан Л.Р. Фордом и Д.Р. Фалкерсоном. Этот обобщенный метод предусматривает инкрементное увеличение потоков вдоль пути от истока *s* к стоку *t*.

Идентификация самоорганизованного веб-сообщества – в соответствии с нашим определением – это неразрешимая в общем случае задача, так как она относится к семейству NP-полных задач разбиения на графах [11]. Тем не менее, если исходить из факта существования одного или более “зерновых” веб-ресурсов и использовать систематические закономерности в структуре веб-графа, задача может быть сформулирована в виде, который позволяет эффективно идентифицировать веб-сообщества с использованием полиномиальных алгоритмов. Под “зерновым” понимают веб-ресурс (веб-страницу), который является признанным авторитетом в тематической области идентифицируемого веб-сообщества и однозначно ему (сообществу) принадлежит.

```

procedure EXACT-FLOW-COMMUNITY
input : graph:  $G = (V; E)$ ; set :  $S \subset V$ ; integer :  $k$ .
// Создает искусственные вершины, s и t и
// добавляет их в V.
for all  $v \in S$  do
Add (s; v) to E with  $c(s; v) \equiv \infty$ .
end for
for all  $(u; v) \in E$  do
Set  $c(u; v) \equiv k$ .
if  $(v; u) \notin E$  then add (v; u) to E with  $c(v; u) \equiv k$ .
end for
for all  $v \in V; v \notin S \cup \{s; t\}$  do
Add (v; t) to E with  $c(v; t) \equiv 1$ .
end for
call : MAX-FLOW (G, s, t).
output : all  $v \in V$  все еще соединенных с s
end procedure

```

```

procedure APPROXIMATE-FLOW-COMMUNITY
input : set : S.
while число итераций меньше желаемого do
Построить  $G = (V; E)$  путем просмотра сети на
фиксированную глубину, начиная с S.
Set k to  $|S|$ .
call : C = EXACT-FLOW-COMMUNITY (G; S; k).
Посчитать ранг для всех  $v \in C$  по числу ребер в C.
Добавить не зерновые вершины с высоким рангом в
S.
end while
output : all  $v \in V$  все еще соединенных с s.
end procedure

```

Таблица 1. Алгоритм для выделения веб-сообществ.

Определим сообщества в терминах ненаправленных графов, где каждое ребро имеет емкость. Т.о. граф, полученный из Веб, теряет информацию о направленности ребер.

Определение 1. Сообщество есть подмножество вершин $C \subseteq V$, таких, что для всех вершин $v \in C$, v имеет множество ребер, соединяющих ее с вершинами в C и практически не имеет ребер, соединяющих с вершинами в $(V - C)$.

Это определение можно сравнить с утверждением: “Сайт о Покемонах, это сайт, который ссылается или имеет больше ссылок на(с) других сайтов о Покемонах, нежели на(с) сайтов не о Покемонах”. Рисунок 1 показывает пример сообщества (слева), отделенного от остального графа (справа). Определим две количественные характеристики, соответствующие истоку и стоку.

Определение 2. Пусть количество ссылок, связанных с истоком, $s\#$, соответствует количеству ребер между s и всеми вершинами в $(C - s)$. Аналогично, пусть количество ссылок со стоком, $t\#$, соответствует количеству ребер между t и вершинами $(V - C - t)$.

Теорема 1. Сообщество C может быть идентифицировано путем вычисления s - t минимального сечения G при условии что s и t будут использованы как исток и сток, соответственно. Предусматривается, что оба $s\#$ и $t\#$ выходят за пределы размера текущего множества. После сечения, вершины, которые остались достижимы из s , находятся в сообществе.

Условия, наложенные на $s\#$ и $t\#$ в теореме 1, не позволяют найти тривиального решения для получения множества вершин истока или стока из остального графа. Несмотря на это, возможно обобщить определение сообщества таким образом, чтобы взвешенные ребра позволяли, используя более высокие веса около вершины истока, получать тривиальные сечения.

Сообщество, которое состоит из сотен или тысяч страниц должно, по-видимому, иметь много ссылок на ресурсы вне сообщества. Это наиболее очевидно, когда рассматривается влияние веб-страниц закладок, которые часто имеют много ссылок на сайты, тема которых не связана с сообществом. Как результат, условие, наложенное на $s\#$, проблематично для исполнения, если единственная вершина используется как исток. Мы можем решить эту проблему, используя множество “зерен”, соединенных с единственным узлом виртуального истока. Этот прием работает путем назначения бесконечной емкости ребрам, которые соединяют виртуальный исток с зернами.

Выбор вершины для стока легко автоматизировать по причине некоторых хорошо известных свойств Веб. Как известно, распределение входящих и исходящих ссылок подчиняется степенному закону распределения [1], и веб-порталы, такие как Yahoo!, должны быть расположены очень близко к центру веб-графа. Т.о. выбирая небольшую коллекцию ссылок верхнего уровня веб-

порталов как виртуальный исток, максимальный поток для определения сообщества должен будет извлечь наиболее сильно связанные сообщества из всего Веб, потому что центр графа очень концентрирован в том смысле, что отсюда есть короткий путь на любой веб-сайт.

Одна из проблем при вычислении идеальных сообществ состоит в том, что это требует повторного доступа к входящим и исходящим ссылкам для многих веб-сайтов. Предложенный аппроксимированный метод для идентификации веб-сообществ рассматривается ниже. Рис. 11 иллюстрирует как направленный сетевой паук извлекает страницы и строит граф.




Рисунок 11. Направленное извлечение сообщества и построение графа: (a) виртуальный исток; (b) вершины зерновых веб-сайтов; (c) вершины веб-сайтов на одну ссылку в глубину от любого зернового сайта; (d) ссылки на сайты не в (b) или (c); и (e) вершина виртуального стока.

Посещение начинается с зерновых веб-страниц, показанных как множество (b) на рис. 11, и находит все страницы, которые ссылаются или на которые ссылается зерновое множество. Исходящие ссылки тривиально находимы путем анализа HTML страницы. Входящие ссылки находятся путем запроса к поисковому сервису, который поддерживает модификатор “link” (такому как Google или AltaVista).

Как только URL-и из множества (c) идентифицированы, их HTML скачиваются и все исходящие ссылки запоминаются. Некоторые из этих исходящих ссылок могут ссылаться на страницы уже посещенные (такие как ссылки из (c) на (c) и (c) на (b)); тем не менее, большинство исходящих ссылок из (c) ведут на еще не скачанные страницы (из множества (d)). Страницы, составляющие множество (d) фактически являются эффективно очищенной составной вершиной стока, т.к. каждая из них ссылается на вершину виртуального стока.

Метод для идентификации веб-сообществ имеет ограниченную эффективность, когда представлено малое количество зерновых веб-страниц (скажем, меньше четырех). Проблема в том, что с малым количеством зерен, только относительно малое подмножество сообщества может быть

определено т.к. совокупное количество исходящих ссылок зерен меньше чем размер сечения (количество удаленных ребер). Т.о., нам необходимо расширить процедуру поиска сообщества с помощью метода идентификации новых зерен.

Эта проблема была решена с помощью метода на основе алгоритма Expectation Maximization (EM) [14]. Алгоритм EM - это двухпроходный процесс, который многократно применяет оценку (estimation, шаг “Е”) и максимизацию (maximization, шаг “М”). В случае с идентификацией веб-сообществ, шаг “Е” соответствует использованию алгоритма поиска максимального потока минимальной стоимости для идентификации подмножества сообщества. Новые из исследованных веб-сайтов отмечаются как зерновые. Затем процесс повторяется. Вся процедура идентификации веб-сообществ была приведена в таблице 1. Процедура делает фиксированное количество итераций, обычно 4 т.к. дальше происходит достижение точки, после которой результат не меняется (как раз в районе 4-й итерации).

В заключение следует также сказать, что для решения задачи поиска веб-сообществ используются и другие подходы. Например в работе [15] анализируются следующие подходы:

- на основе классического алгоритма HITS;
- на основе HITS с использованием неглавных собственных векторов;
- на основе комбинированного HITS и латентно-семантического анализа;
- на основе комбинирования анализа гиперссылок с помощью SALSA и анализа текста с помощью TF-IDF метрики.

Литература.

1. A. Broder, R. Kumar, F. Maghoul, P. Raghavan, S. Rajagopalan, R. Stata, A. Tomkins, and J. Wiener. “Graph structure in the Web: Experiments and models”. In WWW9, pp. 309–320, Amsterdam, May 2000. Elsevier Science. (www9.org/w9cdrom/160/160.html).
2. B. D. Davison. “Topical locality in the Web”. In Proceedings of the 23rd Annual International Conference on Research and Development in Information Retrieval (SIGIR 2000), pp. 272–279. ACM, Athens, July 2000. (www.cs.rutgers.edu/~davison/pubs/2000/sigir/).
3. S. Chakrabarti “Mining the Web. Discovering Knowledge from Hypertext” Data. Morgan Kaufmann Publishers, 2003.
4. M. Diligenti, F. M. Coetzee, S. Lawrence, C. L. Giles, M. Gori “Focused Crawling Using Context Graphs”. Proceedings of the 26th VLDB Conference, 2000. pp. 527-534.

5. D. Gibson, J. Kleinberg, and P. Raghavan. Inferring web communities from link topology. In Proc. 9th ACM Conf. on Hypertext and Hypermedia, 1998.
6. G. W. Flake, S. R. Lawrence, C. L. Giles, and F. M. Coetzee. Self-Organization and Identification of Web Communities. *IEEE Computer*, 35(3), 66–71, 2002
7. N. Imafuji and M. Kitsuregawa, "Effects of maximum flow algorithm on identifying web community." In 4th International Workshop on Web Information and Data Management, pp. 43–48, 2002.
8. N. Imafuji and M. Kitsuregawa, "Finding a web community by maximum flow algorithm with hits score based capacity." In 8th International Conference on Database Systems for Advanced Applications, pp. 101–106, 2003.
9. N. Imafuji and M. Kitsuregawa, "Finding Web Communities by Maximum Flow Algorithm using Well-Assigned Edge Capacities."
10. J. Kleinberg, S. Lawrence. The structure of the Web // *Science*, vol 294, November 2001. pp. 1849-185.
11. Майника Э. Алгоритмы оптимизации на сетях и графах. – М.: «Мир», 1981. – 323 с.
12. G. Flake, S. Lawrence, and C. L. Giles. Efficient identification of web communities. In 6th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 150–160, 2000.
13. R. Kumar, P. Raghavan, S. Rajagopalan, and A. Tomkins. Crawling the Web for emerging cyber-communities. In Proceedings of the 8th International World Wide Web Conference, pp. 1481–1493, 1999.
14. A.P. Dempster, N.M. Laird, and D.B. Rubin. Maximum likelihood from incomplete data via the EM algorithm. *J. R. Statist. Soc. B*, 39:185-197, 1977.
15. Д.Д. Козлов, А.А. Белова. Исследование эффективности применения методов совместного анализа текстов и гиперссылок для поиска тематических сообществ (http://company.yandex.ru/grant/2005/06_Kozlov_102805.pdf)