

План лекций по спецкурсу “Информационно-поисковые системы”

№ Лек.	Тема	Содержание	Литература
1	Введение. Проблема информационного поиска.	Проект “How Much Information”. Объемы производимой информации. Суммарное годовое потребление информации жителями США. Проблема экспоненциального разрыва между производством и потреблением. Подходы к решению проблемы. Жизненный цикл информационного ресурса. Средства навигации для текстовой информации: этапы становления. Библиотечные поисковые системы. Информационный поиск: этапы становления. Исторические исследовательские документально-поисковые системы.	1. Презентация 01. 2. Проект “How Much Information” (http://www2.sims.berkeley.edu/research/projects/how-much-info-2003/)
2	Анализ задачи информационного поиска. Ч.1	Информационный поиск vs. выборка данных. Определение информационного поиска (Information Retrieval). Структура процесса информационного поиска. Особенности Web, затрудняющие классический информационный поиск.	1. Презентация 02. 2. C. J. Rijsbergen Information Retrieval. London: Butterworths, 1979 3. R. Baeza-Yates, B. Ribeiro-Neto Modern Information Retrieval. Addison Wesley, 1999.
3	Анализ задачи информационного поиска. Ч.2	Ключевые проблемы информационного поиска. Релевантность vs. пертинентность. Виды релевантности. Эффективность. Технико-экономическая эффективность. Функциональная эффективность. Себестоимость запроса. Полнота, точность, избирательность. Полнота vs. точность. Уровни отсека. Е-мера. TREC. РОМИП.	1. Аветисян Р.Д., Аветисян Д.О. Теоретические основы информатики. М.: РГГУ, 1997. 2. Презентация 03.
4	Становление ИПС Web: краткий	Становление ИПС Web: краткий исторический обзор. Становление ИПС Web в России.	1. Презентация 04. 2. Презентация 05.

	исторический обзор. Математические модели документального поиска. Ч.1.	Обобщенное описание модели документального поиска. Типы математических моделей документального поиска. Теоретико-множественная модель. Метрики подобия. Простая булевская модель. Расширенная булевская модель. Достоинства и недостатки булевских моделей.	3. Аветисян Р.Д., Аветисян Д.О. Теоретические основы информатики. М.: РГГУ, 1997.
5	Математические модели документального поиска. Ч.2.	Векторная модель. Закон Ципфа (Zipf). Принцип Луна (Luhn). Расчет весов терминов. Достоинства и недостатки векторной модели. Правило принятия решения. Оценка вероятности на основе обратной связи по релевантности (Robertson&Jones). Достоинства и недостатки вероятностных моделей.	1. Презентация 05. 2. Аветисян Р.Д., Аветисян Д.О. Теоретические основы информатики. М.: РГГУ, 1997. 3. S.E.Robertson, K.S.Jones Simple, proven approaches to text retrieval. Cambridge Technical Report, 1997.
6	Математические модели документального поиска. Ч.3.	Матричная модель. Матрицы сопряженности типа “документ-термин”, “документ-документ”, “термин-термин”. Моделирование обработки запроса пользователя. Итерационное уточнение запроса. Энтропийная модель.	1. Презентация 05. 2. Аветисян Р.Д., Аветисян Д.О. Теоретические основы информатики. М.: РГГУ, 1997.
7	Алгоритмы документального поиска. Ч.1.	Полнотекстовое сканирование. Файлы сигнатур. Сигнатуры слов. Сигнатуры документов. Ложные совпадения. Инверсия.	1. Презентация 06. 2. C.Faloutsos, D.Oard A survey of Information Retrieval and Filtering Methods. Technical Report, University of Maryland Computer Science Dept., College Park, MD. 3. J.Zobel, R.A.Moffat, K.Ramamohanarao. Inverted Files Versus Signature Files for Text Indexing - ACM Transactions on Database Systems, Vol. 23, No. 4, December 1998, Pages 453–490.
8	Алгоритмы документального поиска. Ч.2.	Использование семантической информации. Обработка естественного языка (NLP). Латентно-семантическое индексирование (LSI).	1. Презентация 06. 2. C.Faloutsos, D.Oard A survey of Information Retrieval and Filtering Methods. Technical Report, University of Maryland Computer Science Dept., College Park, MD. 3. D.Lewis, K. Sparck Jones Natural Language Processing for Information Retrieval. Communications of the ACM, 39(1) Jan. 1996 4. S.Deerwester, S.T.Dumais, G.W.Furnas, T.K.Landauer, R.Hars hman Indexing by Latent Semantic Indexing. JASIS, 1990.
9	Классификация и кластеризация	Классификация, автоматическая классификация, кластеризация документов. Использование	1. Презентация 06-2. 2. S.A.Macskassy, A.Banerjee, B.D.Davison, H.Hirsh “Human

	документов	автоматической классификации при информационном поиске. Кластеризация. Методы кластеризации. Метод К-средних. Иерархическая кластеризация. Поиск кластера. Кластеризация в распределенных системах. Подходы к кластеризации в распределенных системах. Выполнение запроса в распределенной системе. Классификация документов на основе гиперссылок. Модификация запросов. Метод Rocchio.	Performance on Clustering Web Pages”. Technical Report DCS-TR-355, Department of Computer Science, Rutgers University, 1998. 3. C.Faloutsos, D.Oard A survey of Information Retrieval and Filtering Methods. Technical Report, University of Maryland Computer Science Dept., College Park, MD. 4. S. Chakrabarti Mining the Web. Discovering Knowledge from Hypertext Data. Morgan Kaufmann Publishers, 2003. 5. J. Xu, W.B.Croft "Cluster-based language models for distributed retrieval." In Proceedings of the 22nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 99), 1999.
10	Информационный поиск в Веб. Ч.1.	Особенности Web, затрудняющие классический информационный поиск. Характеристики статического (поверхностного) Веб. Размер базы поисковых систем (2005). Глубинный Веб. Действия пользователя. Таксономия поиска в Веб. Эволюция поисковых систем Веб. Веб-каталоги vs. поисковые системы. Усредненный “портрет” пользователя ИПС Веб.	1. Презентация 07. 2. A.Broder “A taxonomy of Web search”. SIGIR Forum, 36(2), Fall 2002. (http://sigir.org/forum/F2002/broder.pdf) 3. Ray Larson “Principles of Information Retrieval”. Слайды (http://www.sims.berkeley.edu/academics/courses/is240/s06/) 4. D.Carmel, A.Soffer “Information Retrieval”. Слайды. (http://cs.haifa.ac.il/courses/infor/)
11	Информационный поиск в Веб. Ч.2.	Основные задачи, решаемые поисковыми системами Веб. Основные компоненты информационно-поисковой системы Веб. Сбор документов из сети Веб. Обход веб-графа. Сетевые роботы-“пауки”. Типовая структура “паука”. “Узкие места” в работе “паука”. Типичные проблемы при разработке крупномасштабного “паука”. DNS: кеширование, предвыборка, разрешение имен. Проблема одновременной множественной загрузки документов. Одновременная множественная загрузка документов: подходы. Обход веб-графа: общие вопросы. Стратегии обхода веб-графа. Ограничение доступа для робота. Актуальность метапоиска. Структура метапоисковой системы.	1. Презентация 07. 2. Soumen Chakrabarti “Mining the Web. Discovering Knowledge from Hypertext Data”. Morgan Kaufmann Publishers, 2003. 3. Mercator: A scalable, Extensible Web Crawler (http://www.cindoc.csic.es/cybermetrics/pdf/68.pdf) 4. Ray Larson “Principles of Information Retrieval”. Слайды (http://www.sims.berkeley.edu/academics/courses/is240/s06/) 5. D.Carmel, A.Soffer “Information Retrieval”. Слайды. (http://cs.haifa.ac.il/courses/infor/)
12	Информационный поиск в Веб. Ч.3.	Индексирование документа. Преобразование полнотекстового документа в набор индексных	1. Презентация 07. 2. Ray Larson “Principles of Information Retrieval”. Слайды

		терминов. Использование текста входящих гиперссылок. Выполнение запросов.	(http://www.sims.berkeley.edu/academics/courses/is240/s06/) 3. D.Carmel, A.Soffer "Information Retrieval". Слайды. (http://cs.haifa.ac.il/courses/infor/) 4. R. Baeza-Yates, B. Ribeiro-Neto "Modern Information Retrieval". Addison Wesley, 1999.
13	Анализ гиперссылок при информационном поиске в Веб	Базовые допущения при анализе гиперссылок. Алгоритмы анализа гиперссылок. Алгоритм PageRank. Расчет коэффициентов PageRank. Алгоритм HITS. Авторитеты и концентраторы. Процедура расчета весов авторитетности и концентрации. Алгоритм HITS: проблемы. Алгоритм HITS: расширения. Различие между PageRank и HITS.	1. Презентация 08. 2. L.Page, S.Brin, R.Motwani, T.Winograd. "The PageRank citation ranking: Bringing order to theWeb". Stanford, Digital Library Technologies, Working Paper 1999-0120, 1998. 3. M. Kleinberg "Authoritative sources in a hyperlinked environment". Journal of the ACM, 46(5):pp. 604–632, 1999. 4. M.Henzinger "Link Analysis in Web Information Retrieval". Bulletin of the IEEE Computer Society Technical Committee on Data Engineering, 2000. 5. M.Henzinger "Link Analysis in Web Information Retrieval". Bulletin of the IEEE Computer Society Technical Committee on Data Engineering, 2000. 6. A.Borodin, G.O.Roberts, J.S.Rosenthal, P.Tsaparas "Link Analysis and Experiments". ACM Transactions on Internet Technology, Vol.5, No.1, February 2005, P. 231–297.
14	Поисковая оптимизация и спамдексирование.	Спамдексирование. Спамдексирование vs. поисковая оптимизация. Методы спамдексирования. Контентный спам. Ссылочный спам. Методы противодействия спамдексированию.	1. T.Jones "Both Sides of the Digital Battle for a High Rank from a Search Engine". Association for Computing Machinery New Zealand Bulletin, 2005. 2. Презентация 08-2.
15	Архитектура информационно-поисковой системы Google (1998)	Общая структура ИПС Google (1998 г.). Основные структуры данных. Хранилище. Документальный индекс. Словарь. Списки вхождений (hits). Прямой индекс. Обратный индекс. Архитектура Google сегодня.	1. Презентация 09. 2. S.Brin, L.Page "The anatomy of a large-scale hypertextual web search engine". Proc. 7th World Wide Web Conf. (WWW7), p. 107–117.
16	Использование самоорганизации в сети Веб для повышения эффективности ИПС.	Регулярность в распределении гиперссылок. Степенной закон распределения гиперссылок в веб-графе. Модель предпочтительного прикрепления. Структура "бабочка". Сфокусированный обход веб-графа. Радиус-1 гипотеза. Радиус-2 гипотеза. Контекстный граф. Сфокусированный сетевой робот. Контекстно-сфокусированный сетевой робот.	1. Презентация 10. 2. Презентация 11. 3. S. Chakrabarti "Mining the Web. Discovering Knowledge from Hypertext Data". Morgan Kaufmann Publishers, 2003. 4. B.D.Davison. "Topical locality in the Web". In Proceedings of the 23rd Annual International Conference on Research and

		Веб-сообщества. Модель веб-сообщества. Идентификация веб-сообществ на основе алгоритма поиска максимального потока минимальной стоимости.	Development in Information Retrieval (SIGIR 2000), Athens, Greece, July 2000. 5. M.Diligenti, F.M.Coetzee, S.Lawrence, C.L. Giles, M.Gori "Focused Crawling Using Context Graphs". Proceedings of the 26th VLDB Conference, 2000. pp. 527-534. A. Broder, R. Kumar, F. Maghoul, P. Raghavan, S. Rajagopalan, R. Stata, A. Tomkins, and J.Wiener. "Graph structure in the Web: Experiments and models". In WWW9, pp. 309–320, Amsterdam, May 2000. Elsevier Science. (www9.org/w9cdrom/160/160.html) 6. G. W. Flake, S. R. Lawrence, C. L. Giles, and F. M. Coetzee. Self-Organization and Identification of Web Communities. IEEE Computer, 35(3), 66–71, 2002 7. N. Imafuji and M. Kitsuregawa, "Finding a web community by maximum flow algorithm with hits score based capacity." In 8th International Conference on Database Systems for Advanced Applications, pp. 101–106, 2003.
--	--	--	--